

data-authority

数据来源与权威链

定位：中文工作文档。回答” 选课该以哪个源为准”。结论不是” 选一个源”，而是**逐字段定权威**。

○、本轮更正（重要）

前一轮我写过两句不准确的话，这里更正：

1. ”——开课周/星期节次只有第三方源有” → **错**。官方教务公开库 <https://jwbaucas.ac.cn/sc/public/coursePublic> 的**每门课的详情页**就带「上课时间（星期 + 节次）+ 上课地点 + 上课周次」。
2. ”——官方工作簿没有校区字段、公开库没有容量” → 前半句对（第三方源确实没有校区字段），但**官方公开库两者都有**：开课校区是它的一列，限选/已选也是。

一、五个来源，各自的位置

（表情）官方教务公开库 jwbaucas.ac.cn/sc/public/coursePublic

- 形态：服务端渲染 HTML，无分页；POST termId+campusCode 过滤
- 时态：**当前态**（可随时重抓，带抓取时间戳）
- 玉泉路覆盖（2026 秋）：**341 门**（campusCode=20）
- 权威字段：开课校区、课程属性、学分、课时、限选/已选、教师、**开课周 + 星期节次**（详情页）
- 缺什么：培养方案要求；” 我实际选中的课”

（表情）官方工作簿 **xlsx**（开课计划表 0828、核心课和专业课列表 0828）

- 形态：教务发布的表格
- 时态：计划态（发布后基本不变）
- 玉泉路覆盖（2026 秋）：732 条记录 / 414 门
- 权威字段：开课学期（★ 只有它有）
- 缺什么：开课周、星期节次、容量

（表情）UCAS 选课系统（SEP）

- 形态：在线系统，需登录
- 时态：实时态 + 最终态
- 玉泉路覆盖（2026 秋）：全校

- 权威字段：“能不能选上”的最终事实
- 缺什么：需登录；2026-09-18 12:30 已封网

〔表情〕第三方工具内置课程库（courseplanner 公开库）

- 形态：第三方整理 JSON
- 时态：快照态（更新时间 2026-09-14 13:00）
- 玉泉路覆盖（2026 秋）：347 门
- 权威字段：教室、考试方式、授课方式（补充信息）
- 缺什么：无校区字段（只能靠编码第 18 位推）、无学期

〔表情〕你的手工周表

- 形态：你排的 xlsx
- 时态：人工结果态
- 玉泉路覆盖（2026 秋）：9 门课表
- 权威字段：你已做出的取舍
- 缺什么：—

实测交叉验证：〔表情〕与〔表情〕对同一门课的「星期 + 节次 + 周次」**完全一致**（例：实用最优化算法 = 周三第 5-7 节，周 2-5、7-17）。两个独立管线得到同一结果 → 说明这两个字段在两边都可信，**但〔表情〕才是权威**（官方、可重抓、带校区与官方容量口径）。

二、逐字段定权威（这张表才是答案）

字段	权威源	理由
开课校区	〔表情〕官方公开库	真字段；不必再用“课程编码第 18 位 = Y”去推
课程属性 / 学分 / 课时	〔表情〕官方公开库（〔表情〕可互相印证）	官方口径
开课周 / 星期节次 / 上课地点	〔表情〕官方公开库（详情页）	可重抓、带时间戳
限选 / 已选 / 剩余座位	〔表情〕官方公开库	官方口径；〔表情〕只是快照
开课学期	〔表情〕官方工作簿	〔表情〕不按课程给学期；〔表情〕完全没有
我实际选中的课 / 最终结果是否培养方案要求	〔表情〕选课系统 培养方案文件（校发培养字〔2025〕92 号）	只有它有 五个来源全无
教室 / 考试方式 / 授课方式（辅助）	〔表情〕第三方	〔表情〕只给地点，不给考试与授课方式

结论：以〔表情〕为主，〔表情〕只用来补“开课学期”，〔表情〕降为交叉验证与辅助信息，〔表情〕只在需要“最终结果”时用。

三、爬取方案与合规边界

- 入口：列表页 POST /sc/public/coursePublic (termId + campusCode)，详情页 GET /sc/course/coursetime/<id>。无需登录、无需验证码——它就是给公众看的公开库。
- 实测规模：2026 秋季全校 **2970** 行；玉泉路 (campusCode=20) **341** 行。
- 脚本：src/fetch_official_db.py (本仓库)
 - 带本地 **HTML 缓存** (raw/official-cache/, 已 gitignore) → 可断点续爬、重跑不重下
 - 每轮记录**抓取时间戳**与**两份 sha256** (列表页、冻结输出)
 - 礼貌延时 --sleep 0.25, 失败重试 3 次
- 合规：只读公开页面、低频、不提交、不批量抢课。**不做自动选课。**
- **termId 备忘**：2026—2027 学年 (秋) 第一学期 = 89576; (春) 第二学期 = 89577。校区 campusCode: 玉泉路 20、中关村 21、雁栖湖 22。

四、官方数据的导入路径 (第三方工具自己写的)

第三方站点在弹窗里明确提示：数据不新时，去 SEP 系统的” 学期课表” 复制数据 → 粘贴到 Excel (建议直接复制表格，不要点” 导出”) → 保存为.xlsx → 在本页” 课程目录” 上传导入。

也就是说，第三方工具的” 官方工作簿” 路径其实依赖人工从 SEP 复制粘贴——这解释了两件事：① 为什么导入结果可能有偏差 (人工复制 + 导入器解析)；② 为什么现在我们可以用〔表情〕直接把这一层替换掉。

五、还剩的两个缺口

1. 培养方案要求：五个来源全无 → 必须人工输入 (已在 data/degree-requirements.json 固化)。
2. ” 我实际选中的课”：只有〔表情〕选课系统有；封网后 (9-18 之后) 主要靠导出结果核对。

七、” 考核方式” 这类字段的出处 (反查记录)

我实测反查了三个官方面 (列表页 12 列、coursetime 时间地点、courseplan 课程大纲)，**关键词命中全为 0**：

考试方式 / 考核方式

- jwba 列表页：0
- coursetime：0
- courseplan：0
- 官方工作簿：无该字段

授课方式

- jwba 列表页：0
- coursetime：0
- courseplan：0
- 官方工作簿：无该字段

是否远程教学 / 助教 / 培养层次

- jwba 列表页: 0
- coursetime: 0
- courseplan: 0
- 官方工作簿: 无该字段
- courseplan 页是**课程大纲**（教学目的要求、预修课程、大纲内容章节表、教材信息、参考书、课程教师信息）——不含考核方式。
- 官方工作簿的字段只有 10 个: 序号/开课院系/课程编码/课程名称/开课校区/开课学期/课程属性/课程所属学科/学时/学分。

第三方的字段集却是: 培养层次 / 所属学科专业 / 限选 / 已选 / 开课周 / 星期节次 / 教室 / 授课方式 / 考试方式 / 首席教授 / 主讲教师 / 助教 / 是否远程教学。它包含 **限选/已选**（只有**选课系统**才有）和 **是否远程教学/助教**（只有**登录后的教务/选课视图**才有）。考核方式的取值也是一套下拉枚举: 闭卷笔试 / 课堂开卷 / 大开卷 / 读书报告 / 文献综述 / 其它（需说明）。

第三方站点自己声明了来源: 它的弹窗写着” 如果发现本站数据库未及时更新, 请前往 **SEP 系统的『学期课表』** 获取最新数据: 直接复制需要的课程数据, 保留表头和完整的分段排课记录, 粘贴到 Excel…在本页『课程目录』点击『上传课表』导入”, 并注明” 内置课程库” 由维护者定期更新（实测其更新时间为 2026-09-14 13:00）。

结论:

- **强证据**: jwba 三处 0 命中、工作簿无该字段、第三方字段集含只有选课系统才有的字段、第三方自述来源为 SEP。
- **属推断、未直接验证**: SEP「学期课表」页的具体列我没看到——**SEP 是登录门户**(sep.ucas.ac.cn, 用户名/密码), 没有登录态就进不去。所以这条是” 第三方自述 + 字段特征” 推出的, 不是我看过原始页面。
- **彻底证实只需一步 (你来, 约 30 秒)**: 登录 SEP 打开” 学期课表”, 看列里有没有「考试方式 / 授课方式 / 是否远程教学」。有 → 出处锁死。

这件事的实际影响 (比” 出处是谁” 更重要):

1. 考核方式 是**人工从登录页复制粘贴**得来 → 存在复制误差 (列错位、漏行) 的可能, 不能当作逐行可信的官方口径。
2. 它**不在任何公开接口里** → 我们不能自动刷新它, 只能当**辅助字段**并在界面上标注来源 (原型已标注” 来源: 第三方课程库”)。
3. 要拿到**官方口径**的考核方式, 唯一路径是**登录 SEP 读取** → 想自动化只能设计成” 半自动”: 你登录 (含验证码), 我只做只读抓取。这与之前知网滑块时的分工一致。

决定性证据 (2026-09-27 补): 原始快照的字段名就是 **SEP 的表头**

我们把先前抓取但**不入库**的原始下载 (8,103,455 字节) 重新校验了哈希:

sha256 = 7c6090e40801d1ba4ebf3665c54eafaf4ec6e5e3565d996df74e63fac53e8413 ← 与仓库记录一致

它每条记录里的 fields 字典，键恰好是 19 个、且顺序与集合正是 SEP「学期课表」那一张表的表头：

序号 / 开课单位 / 课程编码 / 课程名称 / 课程属性 / 培养层次 / 课时·学分 / 限选 / 已选 / 开课周 / 星期节次 / 教室 / 授课方式 / 考试方式 / 是否远程教学 / 所属学科/专业 / 主讲教师 / 首席教授 / 助教

其中 限选、已选、是否远程教学、助教、培养层次 只在登录后的 SEP 视图里存在（jwba 公开库与官方工作簿都没有）。第三方站点又恰好告诉用户” 前往 SEP『学期课表』复制数据、保留表头、粘贴到 Excel 导入”。→ ” 第三方数据 = 人工从 SEP 学期课表复制粘贴” 得到实证。

实测各字段有值条数（全库 2991 条）：除 所属学科/专业 2987、主讲教师 2558、首席教授 1528、助教 232 外，其余字段 **2991 条全有值**。

顺带得到两个可用的新字段：

字段	取值分布	对本人的意义
授课方式	课堂讲授为主 2560 / 课堂讨论为主 221 / 实验为主 70 / 其它（需说明）69 / 实践为主 31	判断” 要不要到堂、是不是研讨型”
是否远程教学	否 2991 / 2991	本学期无远程课，该字段对本学期无区分度

固化方式（不破坏原有证据链）：原冻结子集 raw/youquanlu-live-courses.json 的 schema 与 sha256 已被文档引用，**不能改**；因此新增一个独立哈希的冻结文件 raw/aux-sep-fields.json（+.sha256），由 src/freeze_aux_fields.py 生成，并在生成前**强制校验原始下载的 sha256 前缀**，不匹配就拒绝固化。

怎么彻底关掉这个议题（仍建议做，约 30 秒）

登录 SEP 打开「学期课表」，确认表头确实含 考试方式 / 授课方式 / 是否远程教学——一旦确认，出处即闭环。若要自动化，则走**半自动**：你登录（含验证码），我只做只读抓取，抓一份**带时间戳**的 SEP 快照，让” 考核方式” 从” 人工复制的辅助字段” 升级为可复现字段。